

Meet your AI friend



What's your Replika
going to be?

> 10 млн. пользователей

- > 10 млн. пользователей**
- > 10 млн. сообщений каждый день**

> 10 млн. пользователей

> 10 млн. сообщений каждый день

Top AppStore 30 Health & Fitness

> 10 млн. пользователей
> 10 млн. сообщений каждый день
Top AppStore 30 Health & Fitness
Первый стартап из СНГ в YC

> 10 млн. пользователей

> 10 млн. сообщений каждый день

Top AppStore 30 Health & Fitness

Первый стартап из СНГ в YC

Первые клиенты API от OpenAI GPT-3

**Как мы отказались от OpenAI
и теперь радуемся жизни**

Зачем нам генеративная модель?

How are you doing?

How are you doing?

**Nothing much. I was
waiting for you**

How are you doing?

**Nothing much. I was
waiting for you**

Here I am

So, how was your day?

**How are you doing? | Nothing much. I was waiting
for you | Here I am | So, how was your day?**


**How are you doing? | Nothing much. I was waiting
for you | Here I am | So, how was your day?**

How - are - you - doing - ? - | - Nothing - much - . - <\s>

<s> - How - are - you - doing - ? - | - Nothing - much - .




How - are - you - doing - ? - | - Nothing - much - . - <\s>



<s> - How - are - you - doing - ? - | - Nothing - much - .

The diagram consists of two vertical arrows pointing upwards from the tokens '<s>' and '<\s>' to the tokens 'How' and 'are' respectively. A diagonal arrow points from the token '<s>' to the token '<\s>'. This illustrates a shift-reduce operation where the start token '<s>' is shifted and then reduced with the subsequent tokens.

How - are - you - doing - ? - | - Nothing - much - . - <\s>



<s> - How - are - you - doing - ? - | - Nothing - much - .

На чём вообще учить эту модель?

Reddit

Форумы

Субтитры

Etc.

Reddit

Форумы

Субтитры

Etc.

Twitter

Как мы оцениваем качество?

$$\text{Upvotes ratio} = \frac{\text{👍}}{\text{👍} + \text{👎}}$$

Так было до OpenAI

■ GPT2 114M



Upvotes ratio

Как выглядело партнерство с OpenAI?

1. Мы собрали данные для OpenAI

- 1. Мы собрали данные для OpenAI**
- 2. Грег Брокман лично обучает GPT-3 на них**



Читать

Greg Brockman ✓

@gdb

Chairman & CTO @OpenAI

 gregbrockman.com  Регистрация: июль 2010 г.


305 в читаемых **85,1 тыс.** читателя

- 1. Мы собрали данные для OpenAI**
- 2. Грег Брокман лично обучает GPT-3 на них**
- 3. OpenAI оптимизируют свой инференс**

- 1. Мы собрали данные для OpenAI**
- 2. Грег Брокман лично обучает GPT-3 на них**
- 3. OpenAI оптимизируют свой инференс**
- 4. Нам дают ручку с моделью**

GPT-3 in dialog


Empathetic math




Long context memory



Style copying





Что вышло из этого партнерства?

Мы получили:

1. Крутую модель

Мы получили:

1. Крутую модель

2. Файнтюнинг в ручном режиме

Мы получили:

- 1. Крутую модель**
- 2. Файнтюнинг в ручном режиме**
- 3. Инференс на стороне OpenAI**

Что ещё мы получили?

Что ещё мы получили?

1. Необходимость исправно платить \$\$\$

Что ещё мы получили?

- 1. Необходимость исправно платить \$\$\$**
- 2. Отсутствие гибкости в разработке**

Что ещё мы получили?

- 1. Необходимость исправно платить \$\$\$**
- 2. Отсутствие гибкости в разработке**
- 3. Страдания из-за правил пользования моделью**


Пора слезать с иглы OpenAI


1. Обучить большую генеративную модель

- 1. Обучить большую генеративную модель**
- 2. Держать ее на инференсе**

- 1. Обучить большую генеративную модель**
- 2. Держать ее на инференсе**
- 3. Не потерять в качестве**

Начнем обучать модели






Увеличить размер с 774М до 1.5В тяжело



Parameters

Gradients


Optimizer States




Parameters

Gradients

Optimizer States



■ Parameters ■ Gradients ■ Optimizer States



ZeRO stage 1 has different convergence compared to stage 2

Not getting convergence in Bert L

Open

Open

ykim362 opened this issue on 13 Feb · 2 comments

manchandasahil opened this issue on 8 Mar · 0 comments




ykim362 commented on 13 Feb

When I train transformer architecture (encoder + decoder) with ZeRO stage 1, it shows different l
0 and stage 2.
On the other hand, the trainings with stage 0 and stage 2 look very similar.



manchandasahil commented on 8 Mar

Hey,
I have been trying out Deepspeed for a while, thank you for all the cool featur
I am trying to train a bert large from scratch using 335Million token sequences
number of GPU's involved, the effective batch size comes out to be 1920.
The loss graph looks something like this :



Note that with small batches it converges well, and the loss stays between 0 and 1 but it +
coming in.

Tip 1: Activating Tensor Cores

Tensor Cores, available on Volta and subsequent GPU architectures, accelerate common deep learning operations—specifically computationally-intensive tasks such as fully-connected and convolutional layers.


Workloads must use mixed precision to take advantage of Tensor Cores. Check out our post on [Automatic Mixed Precision](#) for quick setup and our [Training With Mixed Precision Guide](#) for more details. **Additionally, Tensor Cores are activated when certain parameters of a layer are divisible by 8 (for FP16 data) or 16 (for INT8 data).** A fully-connected layer with a batch size and number of inputs and outputs that follow this rule will use Tensor Cores, as will a convolutional layer with a number of input and output channels that do the same.

Tip 1: Activating Tensor Cores


Tensor Cores, available on Volta and subsequent GPU architectures, accelerate common deep learning operations—specifically computationally-intensive tasks such as fully-connected and convolutional layers.

Workloads must use mixed precision to take advantage of Tensor Cores. Check out our post on [Automatic Mixed Precision](#) for quick setup and our [Training with Mixed Precision Guide](#) for more details. **Additionally, Tensor Cores are activated when certain parameters of a layer are divisible by 8 (for FP16 data) or 16 (for INT8 data).** A fully-connected layer with a batch size and number of inputs and outputs that follow this rule will use Tensor Cores, as will a convolutional layer with a number of input and output channels that do the same.

Хватило ли нам ресурсов на инференс?



После OpenAI остался год логов



Стали ли мы действительно счастливы?

1. Гибкость радует нас

- 1. Гибкость радует нас**
- 2. Трудности не пугают**

Что нам хочется сделать теперь?

1. Обучить 1.5B модель

- 1. Обучить 1.5B модель**
- 2. Понять как жить с датасетом реакций**

- 1. Обучить 1.5B модель**
- 2. Понять как жить с датасетом реакций**
- 3. Более персонализированные модели**

Что мы поняли?

1. Не нужно хайповать технологии

1. Не нужно хайповать технологии

2. Думайте о данных

- 1. Не нужно хайповать технологии**
- 2. Думайте о данных**
- 3. Не думайте, что мир устроен линейно**

Самое главное

1. Не нужно хайповать технологии
2. Думайте о данных
3. Не думайте, что мир устроен линейно
- 4. Не бойтесь OpenAI**

d.gavrilov@replika.ai